# Analiza statyczna języka Ruby

(Static analysis for Ruby language)

Rafał Łasocha

Praca licencjacka

**Promotor:** prof. Witold Charatonik

Uniwersytet Wrocławski Wydział Matematyki i Informatyki Instytut Informatyki

1 października 2018

#### Streszczenie

Współcześni programiści mogą wybierać spośród wielu różnych edytorów tekstu do edycji kodu źródłowego. Jedną z rzeczy ułatwiających ich pracę jest wsparcie edytora dla danego języka programowania pozwalające na szybkie poruszanie się po definicjach lub podpowiedzi podczas edycji kodu. Praca ma na celu opisanie wtyczki, która dzięki analizie statycznej kodu źródłowego dostarcza te funkcjonalności programistom języka Ruby. Z powodu dynamicznej natury tego języka, analiza statyczna jest wymaga wielu heurystyk i równowagi pomiędzy bezpieczeństwem analizy a użytecznością dla programistów.

Currently programmers have ability to choose from variety of text editors to edit source code. Editor support for programming languages is one of the features allowing programmers to accurate jumping to definitions or providing him with suggestions when editing source code. The purpose of this master's thesis is to describe the plug-in delivering these functionalities to Ruby programmers thanks to static code analysis. Due to Ruby's dynamic nature, static analysis require multiple heuristics and balancing between analysis' safety and usefulness for programmers.

# Spis treści

1.	$\mathbf{W}\mathbf{p}$	rowadzenie	7
	1.1.	Założenia i cele	7
		1.1.1. Utrudnienia w językach słabo typowanych	7
		1.1.2. Utrudnienia w Ruby	8
		1.1.3. Aktualny stan	8
		1.1.4. Założenia i cele	9
2.	Roz	związanie	11
	2.1.	Architektura	11
		2.1.1. Protokół komunikacji z edytorem tekstu	11
	2.2.	Proces pozyskiwania informacji	11
		2.2.1. Funkcjonalności	11
		2.2.2. Indeksowanie	12
3.	Buc	lowanie grafu	15
	3.1.	Wstęp	15
	3.2.	Literaly	15
	3.3.	Literaly tablic	16
	3.4.	Słowniki	16
	3.5.	Zmienne globalne	17
	3.6.	Klasy i moduły	18
	3.7.	Inne stałe	18
	3.8.	Metody	19

6 SPIS TREŚCI

	3.9.	Zmienne lokalne	19
	3.10.	Dziedziczenie	19
	3.11.	Zmienne instancji	20
	3.12.	Eigenclass	20
	3.13.	attr_reader, attr_writer	21
	3.14.	Widzialność metod	21
	3.15.	Wywołania metod	23
	3.16.	Wywołania super	23
	3.17.	Bloki i lambdy	23
	3.18.	Biblioteka standardowa	24
	3.19.	self	25
		Wyjątki	25
	3.21.	Petle	25
	3.22.	Return	25
,	<b>TT</b> 7 •		۰.
4.	wnı	oskowanie typu	<b>27</b>
	4.1.	Typy	27
	4.2.	Funkcja wnioskująca typy	28
	4.3.	Heurystyki obsługi wywołań	29
	4.4.	Obsługa wywołania	31
	4.5.	Wywołania funkcji polimorficznych	34
	4.6.	Inne wierzchołki specjalne	34
	4.7.	Pozostałe wierzchołki	35
5.	Pod	sumowanie	37

# Rozdział 1.

# Wprowadzenie

Współcześnie powstaje wiele narzędzi ułatwiających i przyśpieszających pracę programistów. W szczególności istnieją zintegrowane środowiska programistyczne (IDE), które próbują dostarczyć jak najwięcej takich narzędzi w jednym spójnym środowisku. Wśród najbardziej podstawowych funkcjonalności takich środowisk można znaleźć m. in.:

- skok do definicji (stałej, funkcji lub zmiennej)
- informacja o typie zmiennej
- autouzupełnianie pełnej nazwy aktualnie pisanej stałej, zmiennej lub nazwy funkcji

Niniejsza praca przedstawia jak można wykorzystać analizę statyczną plików źródłowych, aby dostarczyć powyższe funkcjonalności w języku Ruby [5], który z racji swojej dynamicznej natury stawia pewne problemy nie występujące w językach statycznie typowanych.

### 1.1. Założenia i cele

#### 1.1.1. Utrudnienia w językach słabo typowanych

Zintegrowane środowiska nie są niczym nowym i są popularne wśród programistów od wielu lat. Jednakże, trudność implementacji narzędzi bazujących na analizie kodu źródłowego zależy od niektórych cech języków programowania. W językach silnie typowanych jest to znacznie prostsze, ponieważ gdy wiemy już jakiego typu jest zmienna – lista dostępnych nazw funkcji jest łatwa do obliczenia (autouzupełnianie, skok do definicji). Podobnie, języki silnie typowane często mają *static dispatch*, więc w momencie kompilacji wiemy gdzie jest kod źródłowy, który zostanie użyty

w danym wywołaniu funkcji (skok do definicji). Oczywiście, w każdym języku możemy używać konstrukcji, które to zadanie znacznie utrudniają (np. w C, wywołanie funkcji która jest przechowana we wskaźniku), ale nie używa się ich zbyt często. W językach dynamicznie typowanych (takich jak Ruby, Python), gdzie język nie dostarcza kompilatora, który dostarczałby informacji o kodzie źródłowym, informacje te musimy sobie znaleźć sami.

#### 1.1.2. Utrudnienia w Ruby

W języku Ruby, o którym jest ta praca, statyczne wywnioskowanie typu wyrażenia jest szczególnie ciężkie z dwóch powodów:

- wiele różnych dostępnych konstrukcji języka, takich jak wielokrotne dziedziczenie, klasy singletonowe, prepend (przypis: nie wiem jak ten mechanizm się nazywa w nomenklaturze języków programowania) sprawia że zbudowanie hierarchii klas i poruszanie się po niej jest niełatwe
- społeczność rubiego jest przyzwyczajona do korzystania z metaprogramowania w bibliotekach i projektach, a dynamicznie generowane (w czasie uruchomienia programu) nazwy zmiennych, metod oraz klas sprawiają że efektywna statyczna analiza tych fragmentów kodu jest niemożliwa

#### 1.1.3. Aktualny stan

Do tworzenia oprogramowania w Ruby, programiści najczęściej wykorzystują RubyMine IDE [9] lub edytory tekstu wspierane wtyczkami, takie jak Vim [11], Emacs [4] czy Atom [1]. RubyMine dostarcza funkcjonalności wspomnianych we wstępie, jednak jest to narzędzie płatne i zamknięte. Edytory tekstu same w sobie nie posiadają tych funkcjonalności, ale istnieją wtyczki, które w jakiejś części te funkcjonalności dostarczają. Jak to bywa z analizą statyczną, efektywność tych narzędzi to pewne spektrum, jedne narzędzia dostarczają lepsze autouzupełnianie, a inne gorsze. Nie jest to binarne i jakość tych funkcjonalności ma duże znaczenie dla programisty. Najpopularniejsze wtyczki to:

- CTags ([2]) zbiera symbole z całego projektu i ich lokalizacje, nie radzi sobie w żaden sposób z metaprogramowaniem i nie potrafi dostarczyć tych funkcjonalności zależnie od kontekstu (np. skok do definicji metody zależy od miejsca, w którym ją się wywołuje)
- Robe ([8]) dostarcza informacje zależne od kontekstu, ale wykorzystuje bardzo proste heurystyki do zawężenia wyników
- Solargraph ([10]) dostarcza podobne funkcjonalności do tych wymienionych we wstępie, stosuje do tego analizę statyczną oraz wykorzystuje inne źródła (takie jak dokumentacja YARD [12])

• RGL ([7]) – odmiennie od pozostałych narzędzi, dostarcza system typów i inferencję typów do Ruby. Wymaga jednak adnotacji klas i metod, tj. inferencja typów zachodzi tylko w "otypowanych" przez programistę metodach.

#### 1.1.4. Założenia i cele

Celem pracy jest napisanie wtyczki działającej w zwykłych edytorach tekstu, która będzie oferować narzędzia wspierające pracę programisty. Nie powinna wymagać od programisty zaawansowanej konfiguracji oraz żadnego wkładu ze strony programisty (w szczególności pisania adnotacji typów). Powinna dostarczyć jak najbardziej trafne informacje, głównie wykorzystując analizę statyczną, ale również inne źródła, jeśli jest to możliwe. Informacje dostarczane przez wtyczkę niekoniecznie muszą być bezpieczne (w rozumieniu bezpiecznej analizy statycznej), bo jest to tylko wsparcie programisty, pozwalające sprawniej mu się poruszać po kodzie i go pisać. Powinna brać pod uwage jaki kod jest czesto produkowany (a więc – z którym programiści muszą pracować na co dzień), nawet jeżeli jest to kod niekoniecznie dobrej jakości. W szczególności, powinna jak najlepiej sobie radzić z metaprogramowaniem, które jest używane przez społeczność. Ponadto, powinna brać pod uwagę że kod źródłowy Ruby jest napisany w C (a wiec, biblioteki standardowej nie możemy "przeanalizować") oraz w miarę możliwości fakt, że istnieją biblioteki korzystające z FFI (Foreign Function Interface), a więc ich kod źródłowy jest napisany w innym języku (z reguły C).

# Rozdział 2.

# Rozwiązanie

#### 2.1. Architektura

Architektura wtyczki jest dwuczęściowa:

- 1. Protokół komunikacji z edytorem tekstu
- 2. Serwer, który dostarcza funkcjonalności, niezależny od edytora

#### 2.1.1. Protokół komunikacji z edytorem tekstu

We wtyczce wykorzystywany jest LSP ( $Language\ Server\ Protocol,\ [6]$ ). Jest to protokół standaryzujący komunikację pomiędzy edytorami tekstu a serwerami dostarczającymi informacji o projekcie. Dzięki temu, chcąc napisać serwer, który potrafi komunikować się z n edytorami tekstu, wystarczy zaimplementować w tym serwerze protokół LSP, który wspiera edytor tekstu (również często przez oddzielną wtyczkę). Ta część jest czysto inżynieryjna, więc w dalszej części pracy skupię się tylko na algorytmach wykorzystywanych w serwerze.

# 2.2. Proces pozyskiwania informacji

### 2.2.1. Funkcjonalności

Przeanalizujmy jeszcze raz funkcjonalności, które chcielibyśmy uwzględnić w naszym serwerze. Pokażemy, że kluczowe dla ich zaimplementowania są dwa zadania:

- 1. Zebranie informacji o hierarchii klas, modułów oraz występujących w nich metodach
- 2. Wywnioskowanie "typu" (klasy, czasami coś więcej) zmiennych

#### Informacja o typie zmiennej

Już sama informacja o typie jest cenna dla programisty. Implementacja przedstawienia tego typu programiście wynika bezpośrednio z (2). Mówimy o języku dynamicznie typowanym, więc w dalszej części pracy zostanie zdefiniowane czym jest typ. Ponieważ ruby jest językiem w pełni obiektowym i nie ma w nim typów prymitywnych, intuicyjnie typ możemy (z reguły, nie zawsze) powiązać z klasą obiektu, który jest przypisany do zmiennej.

#### Skok do definicji

Programista często chce dowiedzieć się jak wyglądają definicje różnych bytów, takich jak zmienne lokalne, stałe czy metody w kodzie źródłowym.

Przypadek zmiennej lokalnej jest nieskomplikowany i rzadko potrzebny, ponieważ krótkie metody z reguły powodują że definicja jest widoczna na pierwszy rzut oka. Inaczej jest w przypadku stałej. Wbrew pozorom, odszukanie takiej definicji nie jest proste, ponieważ w Ruby stałe mogą być przypisywane ponownie (sic), a reguły zagnieżdżania i referencji nie są łatwe (z reguły są zrozumiałe dla osób z kilkuletnim doświadczeniem).

Jednak najtrudniejszą część, a jednocześnie najbardziej potrzebną jest skok do definicji metody. Metoda jest wywoływana na jakimś obiekcie, więc musimy znać "typ" zmiennej aby zlokalizować odpowiednią definicję.

#### Autouzupełnianie

Pisząc kod, programista chce uniknąć napisania błędnej nazwy metody i pomaga w tym funkcjonalność autouzupełniania. Polega ono na wyświetleniu listy metod które można wywołać na danym wyrażeniu. Podobnie jak w przypadku skoku do definicji, aby wiedzieć jakie metody zaproponować programiście, musimy znać jak najdokładniej typ wyrażenia.

#### 2.2.2. Indeksowanie

Uruchomienie serwera rozpoczyna przeindeksowanie wszystkich plików. Indeksowanie to spora część frontendu typowego interpretera, zawierający analizę leksykalną, składniową i semantyczną. Proces ten polega na trzech etapach:

- 1. Sparsowaniu pliku źródłowego do AST (abstract syntax tree)
- 2. Przejście przez AST funkcją dodającą wierzchołki i krawędzie do DFG (data flow graph) oraz jednocześnie zbierającą informacje o definicjach klas, modułów i metod. Wierzchołki są często przypisane do danego węzła w AST, a więc

również ścieżki i pozycji w pliku. Idea algorytmu budującego graf przepływu dla danych bazującego na AST została zaczerpnięta z pracy DeFouw, Grove i Chambers [3], która miała na celu optymalizację kompilatorów dla obiektowych języków programowania.

3. Uruchomienie funkcji wnioskującej typ wszystkich wierzchołków na podstawie informacji w grafie i hierarchii klas.

# Rozdział 3.

# Budowanie grafu

## 3.1. Wstęp

Graf który budujemy jest skierowany i może zawierać cykle. Wierzchołki są etykietowane, tj. każdy wierzchołek ma swój "rodzaj" oraz być może dodatkowe parametry (zależnie od rodzaju). Ponadto wierzchołek może mieć przypisaną lokalizację w kodzie źródłowym. Lokalizacja składa się ze ścieżki do pliku, pozycji początkowej w kodzie źródłowym (numer linii i numer kolumny) oraz pozycji końcowej w kodzie źródłowym. Krawędzie są nieetykietowane.

# 3.2. Literaly

Na początek warto popatrzeć na najprostsze AST, czyli literały. AST literału liczby całkowitej (np. 42) zostanie przekształcony na pojedyńczy wierzchołek rodzaju int (Rys. 3.1). Rodzaj będzie potrzebny funkcji wnioskującej typy, która na podstawie rodzaju, dodatkowych parametrów wierzchołka oraz wierzchołków z krawędzi wejściowych będzie decydowała jakiego typu jest dany wierzchołek. W tym prostym przypadku wierzchołek nie ma żadnych parametrów i nie zwracamy uwagi na krawędzie wejściowe (bo ich, z metody budowania grafu, dla wierzchołka tego rodzaju nawet nie będzie) tylko przypisujemy wszystkim wierzchołkom rodzaju int typ Nominal(Integer).



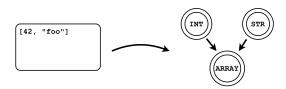
Rysunek 3.1: Budowanie grafu dla literału liczby całkowitej Po lewej kod źródłowy, po prawej graf zbudowany z tego kodu źródłowego.

Tak samo jest z literałami liczbami wymiernych, zmiennopozycyjnych, zespolonych oraz wartości true, false oraz nil.

Podobnie sytuacja ma się w przypadku literałów tekstowych (wierzchołek rodzaju str) oraz symboli (wierzchołek rodzaju sym). Drobna różnica jest taka, że tekst może być z interpolacją (np. ''foo#{somevariable}bar''), a w takim przypadku najpierw rekurencyjnie przetwarzamy wszystkie interpolowane wyrażenia, ponieważ typ wyrażeń interpolowanych też może być potrzebny programiście. Jednakże, funkcja wnioskująca przypisuje wierzchołkowi rodzaju str zawsze typ Nominal(String) niezależnie od krawędzi wejściowych. Analogicznie jest w przypadku symboli.

## 3.3. Literaly tablic

Pierwszym ciekawym przypadkiem jest literał tablicy, np. [42, ''string''] (Rys. 3.2). Dla takiego AST, najpierw budujemy wierzchołki dla wszystkich poddrzew - w tym przykładzie dostaniemy dwa wierzchołki, odpowiednio rodzaju int oraz str. Następnie dodajemy wierzchołek rodzaju array, który będzie wynikiem przetwarzania tego AST, oraz dodamy krawędzie z wierzchołków int i str do wierzchołka array.



Rysunek 3.2: Budowanie grafu dla literalu tablicy

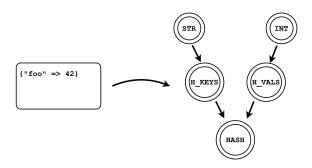
Funkcja wnioskująca typ dla wierzchołka rodzaju array zawsze patrzy na typy wszystkich wierzchołków krawędzi wejściowych, tworzy z nich jeden typ Union – w naszym przykładzie Union(Integer or String) oraz finalnie przypisuje temu wierzchołkowi typ parametryzowany Generic (Array) < Union (Integer or String) >.

### 3.4. Słowniki

W słownikach zarówno klucze i wartości mogą być różnego typu. Literał budowania słownika może również w sobie zawierać klucze (i oczywiście wartości), które nie są literałami. Przetwarzając literał słownika, budujemy trzy wierzchołki: hash, hash\_keys i hash\_values (Rys. 3.3). Następnie przetwarzamy wszystkie klucze, oraz dodajemy dla każdego klucza krawędź pomiędzy wierzchołkiem wyrażenia klucza, a wierzchołkiem hash\_keys. Podobnie przetwarzamy wszystkie wartości i dodajemy krawędź pomiędzy wierzchołkami wartości, a wierzchołkiem hash\_values.

Na końcu, dodajemy dwie krawędzie: pomiędzy hash\_keys oraz hash i hash\_values oraz hash.

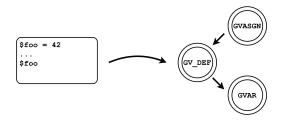
Funkcja wnioskująca typ dla wierzchołka rodzajów hash\_keys oraz hash\_values działa grupująco - tj. zbiera wszystkie typy z wierzchołków z krawędzi wejściowych i łączy je w jeden typ Union(...). Funkcja typująca wierzchołek hash patrzy na rodzaje wierzchołków i buduje finalny typ GenericType(Hash)<typ otrzymany z hash\_keys, typ otrzymany z hash\_values>.



Rysunek 3.3: Budowanie grafu dla literału słownika

## 3.5. Zmienne globalne

W ogólności nie możemy wiedzieć w jakiej kolejności zostaną przypisane zmienne globalne, więc zakładamy, że w momencie referencji zmiennej globalnej jej wartość może pochodzić z dowolnego przypisania tej zmiennej w całym kodzie źródłowym. W tym celu, dla każdego identyfikatora (nie wystąpienia!) zmiennej globalnej tworzymy specjalny wierzchołek rodzaju gvar\_definition (gv\_def na rysunku 3.4). Za każdym razem gdy przetwarzamy przypisanie jakiejś wartości do danej zmiennej globalnej, tworzymy krawędź od tej wartości, do danego wierzchołka gvar\_definition. Odpowiednio, przetwarzając referencję zmiennej globalnej, tworzymy krawędź od gvar\_definition do tej wartości. W ten sposób, funkcja wnioskująca typy przekaże wszystkie możliwe przypisania danej zmiennej globalnej do wszystkich ich wystąpień w programie.



Rysunek 3.4: Budowanie grafu dla zmiennych globalnych

## 3.6. Klasy i moduły

Funkcja budująca graf, przyjmuje jako zależność instancję Bazy danych - na początku przetwarzania projektu pustą. W bazie przechowujemy wszystkie informacje, które pozwalają nam szybko odpowiadać na żądania, które wysyła do nas użytkownik. Dlatego też przechowujemy tam informacje np. o znalezionych podczas budowania grafu definicjach stałych i metod.

Podczas przechodzenia przez AST pliku, przetwarzając wierzchołek definicji klasy lub modułu, zapisujemy tę definicję w bazie. W Ruby klasa (i moduł) są wartościami, więc odrębnie zapisujemy definicję klasy (i informację np. o jej rodzicu), a oddzielnie fakt, że klasa ta została przypisana do pewnej stałej. Pozwala to na wspieranie otwartych klas, oraz w przyszłości klas/modułów anonimowych.

Funkcja budująca graf jest funkcją rekurencyjną przekazującą sobie dwa argumenty: podgraf AST do przetworzenia, oraz kontekst. Kontekst przechowuje kilka informacji o aktualnym stanie budowania grafu. Po pierwsze, wie w jakim zagnieżdżeniu klas / modułów jesteśmy, oraz jeżeli aktualnie przetwarzamy definicję metody, to co to jest za metoda. W kontekście staramy się również w miarę możliwości śledzić czym jest aktualnie self. Ponadto, mamy słownik mapujący identyfikatory obecnych zmiennych lokalnych do ich możliwych definicji (w stylu klasycznej analizy statycznej Reaching Definitions). Wreszcie, trzymamy w nim też krótką informację o aktualnie zadeklarowanej widzialności definiowanych metod (publiczne, prywatne lub chronione).

#### 3.7. Inne stałe

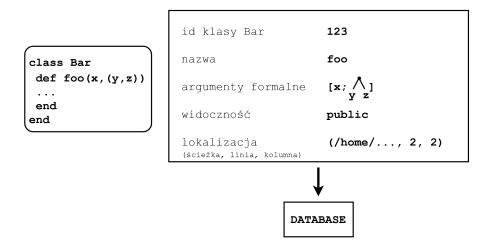
Ponieważ zdefiniowane stałe mają domyślnie globalną widzialność oraz mogą być przypisywane ponownie, ich obsługa nie różni się bardzo od zwykłych zmiennych globalnych. Po pierwsze, odróżnia je to, że nie są prostym identyfikatorem (jak \$foo), ale złożonym z kilku, niekoniecznie statycznych (jeśli x = Foo to x::Bar jest poprawną referencją do Foo::Bar), więc wymagają specjalnych struktur danych w bazie, algorytmu rozwiązywania tych referencji i (przez to, że referencje mogą być dynamiczne) niekoniecznie są zawsze obliczalne w statycznej analizie.

Jest to też pierwsze miejsce, w którym stosujemy heurystyki bazujące na popularnych idiomach w Ruby. Przykładowo, w wyrażeniu NetworkError = Class.new(StandardError) najpierw tworzymy klasę anonimową dziedziczącą po klasie StandardError, a następnie przypisujemy ją do stałej NetworkError. Normalnie, nie wiedzielibyśmy o tym, że NetworkError jest klasą (bo nie śledzimy wartości), ale stosujemy heurystykę szukającą wyrażenia wg wzoru X = Class.new(Y). Jeżeli heurystyka znalazła takie wyrażenie, to postępujemy z nim podobnie jak z definicją klasy. W przeciwnym przypadku, jak z definicją zwykłej stałej.

3.8. METODY 19

## 3.8. Metody

Podobnie jak jest to ze stałymi, podczas budowania grafu zapisujemy w Bazie znalezione definicje metod. Dokładniej, zapisujemy nazwę, identyfikator definicji klasy/modułu wewnątrz której została metoda zdefiniowana, drzewo argumentów formalnych (w Ruby argumenty formalne przez dekonstruktory mają postać drzewa), widoczność, oraz lokalizację w pliku. Zapisujemy też w bazie wierzchołki odpowiadające argumentom formalnym i wartości zwracanej przez metodę. Następnie ustawiamy tę metodę jako aktualnie przetwarzaną w kontekście i budujemy graf dla ciała tej metody.



Rysunek 3.5: Zapisywanie informacji o metodzie do bazy danych

#### 3.9. Zmienne lokalne

Tak jak zostało to wspomniane, wierzchołki o przypisaniach zmiennych lokalnych są przechowywane w kontekście w postaci podobnej do klasycznej statycznej analizy *Reaching Definitions*, więc są dość dokładne. Podczas przechodzenia przez AST, w kontekście przekazujemy słownik mapujący identyfikatory zmiennych lokalnych w aktualnym zasięgu leksykalnym (ang. *lexical scope*) na możliwe przypisania danej zmiennej lokalnej, a dokładniej – wierzchołki tych przypisań.

#### 3.10. Dziedziczenie

Ruby wspiera wiele rodzajów dziedziczenia, ale poszczególne konstrukty nie są od siebie istotnie różne. Jednak ponieważ to po czym dziedziczymy, składniowo, nie musi być identyfikatorem, ale może być dowolnym wyrażeniem (więc poprawne są konstrukty typu class Foo < \$x czy class Foo < self), znowu niemożliwa jest

w pełni poprawna analiza. Aktualnie ograniczamy się tylko do obsługiwania sytuacji gdy to po czym dziedziczymy jest poprawnym identyfikatorem stałej, w przeciwnym wypadku ignorujemy to wyrażenie. W przyszłości łatwo można by wprowadzić heurystykę pozwalającą np. na dziedziczenie po strukturach (class Foo < Struct.new(:field)), ponieważ jest kilka takich idiomatycznych przypadków w których dziedziczymy po wyrażeniach nie będących identyfikatorami.

## 3.11. Zmienne instancji

Skoro Ruby jest językiem obiektowym, nie może zabraknąć zmiennych instancji. Traktujemy je w podobny sposób jak zmienne globalne - nie próbujemy śledzić dokładnego przepływu, tylko zbieramy wszystkie możliwe przypisania zmiennych instancji, wszystkie możliwe użycia, i je łączymy ze sobą przez wierzchołek pośredni ivar\_definition. Aktualnie ignorujemy fakt, że zmienna @x w klasie Foo i Bar jest tą samą zmienną, jeśli Bar jest rodzicem Foo, ale łatwo rozszerzyć kod o tę funkcjonalność.

## 3.12. Eigenclass

Ruby, będąc językiem w pełni obiektowym, nie ma mechanizmu metod statycznych znanego np. z C++, ale ma podobnie działające tzw. metody klasowe. Klasy są obiektem, a jeżeli coś jest obiektem (instancją) to musi mieć również swoją klasę. Naturalnym wydawałoby się, że klasa jest instancją klasy Class, ale w Ruby mamy dodatkowy element – każda definicja klasy tworzy dla tej klasy również eigenclass. Właściwym łańcuchem dziedziczenia jest więc Foo < eigenclass Foo < Class.

Otwierając definicję klasy (ale gdy ciągle nie jesteśmy wewnątrz definicji metody), self jest właśnie instancją tej eigenclass. W definicji klasy możemy wtedy korzystać ze składni def self.foo aby zdefiniować metodę na eigenclass lub class << self aby otworzyć definicję eigenclass. W ten sposób zdefiniowane metody zachowują się jak metody statyczne, tj. można je wywołać przez składnię PewnaKlasa.foo(...).

Składnie te są reprezentowane przez konkretne wierzchołki, ale w miejscu self może być dowolne wyrażenie – możemy więc napisać np. def Foo.bar i zdefiniować metodę na eigenclass klasy Foo będąc wewnątrz kompletnie innej metody. Jednakże prawie zawsze jest to self, więc obsługujemy tylko tę składnię. Obsługa definicji metody wewnątrz eigenclass (def self.foo; ...; end) lub definicji eigenclass (class << self; ...; end) są bardzo podobne do zwykłej definicji metody lub klasy, z tą różnicą, że zamiast zdefiniować metodę na klasie, najpierw pobieramy z bazy eigenclass, a dopiero potem dodajemy definicję. Jeśli eigenclass nie ma, to dodajemy pustą definicję klasy jako tę właśnie eigenclass. Następnie postępujemy tak

jak ze zwykłą metodą, czyli budujemy graf dla ciała tej metody. Różnice w budowaniu metod definiowanych na *eigenclass*, a zwykłymi metodami jest przedstawiona na Alg. 1.

Algorytm 1: Fragmenty funkcji budującej obsługującej definiowanie metody instancji i metody klasowej

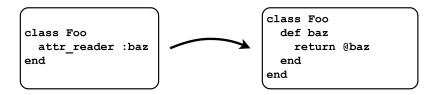
## 3.13. attr\_reader, attr\_writer

Są wbudowane w Ruby metody *klasowe*, które definiują inne metody, więc są już de facto metaprogramowaniem. W bibliotece standardowej Rubiego najpopularniejsze to attr\_reader i attr\_writer. attr\_reader(:foo) definiuje metodę odczytującą zmienną instancji, o takiej samej nazwie. Oczywiście, attr\_reader przyjmuje dowolną liczbę argumentów, więc szybko można za jego pomocą zdefiniować wiele takich funkcji.

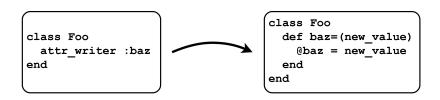
Tutaj funkcja budująca ucieka się do heurystyki wykrywającej użycie funkcji o nazwie attr\_reader i zamiast uznawać to wywołanie za zwykłe wywołanie metody, definiuje odpowiednią metodę dla każdego argumentu (Rys. 3.6). Dodatkowo, ustawia lokalizację występowania definicji tak zdefiniowanej metody na linijkę z attr\_reader, więc programista, który użyje skoku do definicji łatwo dowie się, że metoda ta jest definiowana za pomocą attr\_reader. Bardzo podobnie jest z metodą attr\_writer, która definiuje przypisanie do zmiennej instancji (tzw. setter, Rys. 3.7).

#### 3.14. Widzialność metod

W większości języków obiektowych, private, public i protected są słowami kluczowymi (a przez to - posiadają własne AST), w Ruby jednakże są to zwykłe



Rysunek 3.6: Transformacja wywołania attr\_reader



Rysunek 3.7: Transformacja wywołania attr\_writer

wywołania metod klasowych. Z tego powodu, znowu korzystamy z heurystyk. W tym wypadku jednak takie heurystyki są mniej akceptowalne, ponieważ te nazwy mogą prawdopodobnie pojawić się w produkcyjnych programach – autor tej pracy natknął się na taki przypadek osobiście. Jednak z braku lepszego rozwiązania, stosujemy tutaj również tylko prostą heurystykę po nazwie metody. W tym wypadku, analizujemy argumenty jakie otrzymuje wywołanie metody private i wysyłamy do bazy żądanie zmiany widzialności metod o podanych jako argumenty nazwach, w definicji klasy którą aktualnie przetwarzamy (informację o aktualnie przetwarzanej definicji klasy trzymamy w kontekście).

### Algorytm 2: Fragment funkcji budującej obsługującej wywołanie funkcji

```
1 function buildGraph (ast, context):
 \mathbf{3} if ast.type = 'send' then
 4
       if ast.messageName = 'private' and ast.sendObj = null then
 5
          for methodName \in getMethodNamesToChangeFromAst(ast) do
 6
              database.changeVisibility(context.currentlyAnalyzedKlassId,
 7
               methodName, 'private');
 8
          end
          return;
 9
       end
12 end
```

## 3.15. Wywołania metod

Pomimo tego, że jest to prawdopodobnie najważniejszy AST, jego analiza podczas budowania grafu nie jest bardzo skomplikowana. Funkcja budująca przetwarza rekurencyjnie wyrażenie na którym wywoływana jest metoda oraz przekazywane argumenty. Następnie tworzy dodatkowy wierzchołek na wynik tej metody. Wreszcie, wszystkie te wierzchołki łączy w rekord i wrzuca do kolejki wywołań. Kolejka ta będzie używana dopiero podczas typowania.

## 3.16. Wywołania super

Wywołania super dzielą się na dwa rodzaje (i są to dwa różne wierzchołki AST). Pierwszy to zwykłe wywołanie super(args) znane z innych języków programowania, wywołujące odpowiadającą metodę z definicji rodzica i przekazującą podane do super argumenty. Analiza tego wywołania jest bardzo podobna do zwykłego wywołania metody poza tym, że do rekordu wywołania dopisujemy jeszcze identyfikator aktualnie przetwarzanej metody, aby łatwo znaleźć rodzica i odpowiadającą w nim metodę.

Drugi rodzaj wywołania jest bezargumentowy, tj. super. W takim wypadku, wszystkie argumenty przekazane do tej metody są przez interpreter podane do tego bezargumentowego wywołania super, tj. metoda rodzica zostaje wywołana dokładnie z takimi samymi argumentami. W takim wypadku, jedyne co robimy to zapisujemy w bazie wierzchołek odpowiadający wywołaniu bezargumentowego super.

# 3.17. Bloki i lambdy

Jak w większości współczesnych języków programowania, w Ruby również funkcje są first class citizens, a więc są wartościami, które mogą być przypisywane do zmiennych i przekazywane jako argumenty. W Ruby są obecne też bloki, które są niczym innym jak przekazywaną do wywołania metody funkcją, którą można wywoływać wewnątrz metody za pomocą specjalnej składni yield. Każde użycie składni yield wewnątrz metody wywołuje tę funkcję i przekazuje do niej argumenty (jeśli zostały jakieś przekazane do yield).

Analizując słowo kluczowe yield, tworzymy specjalny rekord składający się z przekazanych argumentów i specjalnego wierzchołka na wynik - bardzo podobnie jak w przypadku wywołania metody. Dodajemy ten rekord do specjalnej listy użyć yield połączonej z definicją aktualnie przetwarzanej metody.

Analizując blok, podejmujemy działania podobne, jak przy definiowaniu zwykłej metody, tj. analizujemy argumenty, przygotowujemy wierzchołki na argumenty formalne, wierzchołek na wynik bloku i wszystko łączymy w rekord. Ruby nie posiada specjalnego słowa kluczowego na zbudowanie funkcji anonimowej, jest to po prostu blok przekazany do funkcji o nazwie lambda. Prosta heurystyka znowu pozwala rozróżnić przypadki, kiedy po prostu budujemy funkcję anonimową, a kiedy przekazujemy blok do wywołania metody. W tym pierwszym przypadku, zapisujemy identyfikator (automatycznie wygenerowany, na potrzeby analizy) tej funkcji w wierzchołku, a w drugim – zapisujemy ten identyfikator przy wywołaniu metody.

### 3.18. Biblioteka standardowa

Ruby jest językiem interpretowanym, więc definicje podstawowych klas i metod są bezpośrednio w interpreterze. Interpreter jest napisany w C, więc tych definicji nie ma napisanych w Ruby. Aby nasza analiza była praktyczna, definicje biblioteki standardowej powinny być w pewien sposób obsłużone.

Metody w bibliotece standardowej możemy podzielić na dwie grupy. W większości metod, jedyne co nas interesuje to zwracany typ – wyobraźmy sobie metody typu File.read(filepath). Wystarczające jest jeżeli o tej metodzie zapiszemy, że zawsze zwraca typ NominalType(String). W taki sposób możemy sobie poradzić z większością metod.

Cięższym przypadkiem są metody przetwarzania danych, takie jak map lub filter w klasie Array. Tablica jest typem parametryzowanym (np. Generic (Array) < Integer>), więc nie ma tutaj stałego typu który moglibyśmy uniwersalnie zwracać. Drugą opcją byłoby dodanie odpowiednich wierzchołków i krawędzi odpowiadających temu, jak dana metoda działa i traktowanie jej dokładnie tak samo jak zwykłe metody podczas typowania (jedyną różnicą byłoby więc to, że graf dla definicji tej metody byłby napisany przez autora analizy, a nie automatycznie na podstawie AST). Jednak podczas typowania, łączymy każde użycie metody z tą samą definicją formalną. Oznaczałoby to, że jeżeli w dwóch różnych miejscach kodu wywołujemy metodę map, raz na obiekcie typu Generic (Array) < Integer>, a raz na Generic (Array) < String>, to wywnioskowanym zwracanym typem dla obu tych wywołań byłby Generic (Array) < Integer or String>. A ponieważ w praktyce wywołujamy map na listach wielu różnych obiektów, taki zwracany typ byłby bardzo długi i bezużyteczny.

Trzecią opcją byłoby zapisanie przez autora analizy tylko wzoru jak wygląda graf dla tej definicji metody, ale tworzenie świeżych wierzchołków i krawędzi tego grafu w każdym miejscu, w którym ta metoda jest wywoływana. Jest to rozwiązanie przyjęte w tej pracy. Oczywistą wadą jest większy rozmiar grafu, ale rozwiązanie to sprawdza się w praktycznych zastosowaniach.

3.19. SELF 25

#### 3.19. self

self jest konstrukcją języków zorientowanych obiektowo, która sprawia problemy przy analizie statycznej. Jest tak ponieważ self jest bardzo często używany (w szczególności właściwie wszystkie wywołania metod prywatnych to wywołania na wyrażeniu self) oraz jednocześnie jego dokładny typ jest trudny do określenia. Nasza analiza korzysta z bardzo uproszczonego założenia, że self jest zawsze typem odpowiadającym definicji klasy, w której jest użyte. W przyszłości jednak można by było spróbować z założeniem, że self jest typu odpowiadającego danej definicji klasy lub jednej z jej podklas. Z jednej strony, takie rozwiązanie byłoby bardziej bezpieczną analizą. Z drugiej strony, w każdym projekcie są klasy podstawowe, po których dziedziczy wiele innych definicji klas. W takich przypadkach bezpieczniejsze podejście mogłoby się okazać niepraktyczne, ponieważ self byłby typowany jako unia np. 100 różnych klas.

## 3.20. Wyjątki

Obsługa wyjątków nie jest skomplikowana i główną trudnością jest odpowiednie obsłużenie zasięgu leksykalnego dla zmiennych lokalnych. Jedyną rzeczą wartą wspomnienia jest fakt, że raise SomeError jest pierwszym przykładem wyrażenia, któremu celowo przypisujemy podczas typowania typ Bottom (tj. brak typu), ponieważ nie zwraca to wyrażenie żadnej wartości.

## 3.21. Petle

Pętle i słowa kluczowe z nimi związane (break, next itp.) również nie są zbyt interesujące. Po pierwsze dlatego, że z reguły wyrażenia związane z pętlami zwracają nil lub nic (tj. są typu Bottom), więc jedyne na co trzeba uważać, to znowu poprawne obsłużenie zasięgu leksykalnego zmiennych lokalnych. Po drugie dlatego, że pętle w ruby są używane bardzo rzadko i iteracje w idiomatycznym Ruby wyraża się za pomocą funkcyjnych map, filter, each i innych.

### 3.22. Return

Ruby posiada znane z innych języków programowania słowo kluczowe return, kończące wykonywanie funkcji i zwrócenie wartości jako wynik funkcji. Aby to wspierać, pobieramy z kontekstu wierzchołki aktualnie przetwarzanej metody, a wśród nich wierzchołek rodzaju call\_result. Jedyne co musimy zrobić to dodać krawędź pomiędzy wierzchołkiem wyrażenia przekazanego w return, a wierzchołkiem call\_result pobranym wcześniej z kontekstu.

# Rozdział 4.

# Wnioskowanie typu

# 4.1. Typy

Mamy następujące typy:

- Bottom typ oznaczający brak typu, używany kiedy typ wierzchołka jest jeszcze nie znany lub typu nie posiada (np. słowa kluczowe raise lub break)
- NominalType(Foo) podstawowy typ, oznacza że wyrażenie jest instancją klasy Foo.
- ClassType(Foo) typ oznaczający że wyrażenie jest klasą Foo. Innymi słowy, jest instancją klasy Class lub instancją eigenclass klasy Foo, ale tak dokładna informacja jest oczywiście przydatniejsza niż samo NominalType(Class), dlatego mamy oddzielny typ na ten specjalny przypadek.
- GenericType(Foo)<typ1, typ2, ...> typ oznaczający jeden z typów generycznych. Opisane w pracy są dwa: Array posiadający jeden parametr, oraz Hash posiadający dwa parametry (typ kluczy i typ wartości). Parametry są typami. Można sobie łatwo wyobrazić rozszerzenie na inne klasy z biblioteki standardowej, takie jak Set lub Range.
- UnionType(typ1, typ2, ...) typ oznaczającą dowolny z wymienionych typów. Większość rodzajów wierzchołków w funkcji typującej jedyne co robi to bierze typy z wszystkich wierzchołków wejściowych i tworzy z nich jeden UnionType.
- MainType typ szczególny, mało istotny w typowaniu. Definicje metod, które są zdefiniowane nie w definicji klasy, są zdefiniowane na specjalnym obiekcie main.

## 4.2. Funkcja wnioskująca typy

Kiedy graf jest gotowy, przekazujemy go do funkcji wnioskującej typy wszystkich wierzchołków (Alg. 3 i 4). Funkcja ta jest podzielona na kilka etapów. Do kolejki z wierzchołkami są na początku dodawane wszystkie wierzchołki, a typ wszystkich jest ustawiany na Bottom. Następnie przetwarzamy każdy wierzchołek (nazwijmy go X) z kolejki. Jeżeli po inferencji typu, typ wierzchołka X się zmienił, patrzymy na wszystkie krawędzie wychodzące z X i dodajemy docelowe wierzchołki tych krawędzi do kolejki, jeśli ich tam jeszcze nie ma. Gdy przetworzymy wszystkie wierzchołki, przechodzimy do przetwarzania wywołań metod. Wywołanie metody przetwarzamy tylko, jeśli wszystkie jej argumenty oraz obiekt na którym wywoływana jest metoda, są ukonkretnione (tj. żaden z nich nie jest typu Bottom). Następnie, w zależności od obliczonego typu wyrażenia na którym jest wywoływana metoda, oraz jej nazwy, zachodzi kilka heurystyk opisanych w następnych częściach.

Algorytm 3: Pseudokod funkcji typującej

```
1 function typeNodes (nodesWorklist, messageSendsWorklist):
 2 while !nodesWorklist.empty? do
      while !nodesWorklist.empty? do
 3
          while !nodesWorklist.empty? do
             processNode(nodesWorklist.pop())
 5
          end
 6
          for messageSend \in messageSendWorklist do
             if satisfiedMessageSend?(messageSend) then
 8
                 processMessageSend(messageSend)
 9
             end
10
          end
11
      end
12
      for messageSend \in messageSendWorklist do
13
         processMessageSend(messageSend)
14
      end
16 end
```

Schemat we wszystkich jest podobny i polega na znalezieniu w bazie definicji metody, która została wywołana, a następnie połączeniu wierzchołków argumentów wywołania z argumentami formalnymi oraz wierzchołka wyniku metody z wierzchołkiem wyniku wywołania. Dzięki temu że wszystkie argumenty są zdefiniowane, możemy tutaj przeprowadzić kilka dodatkowych heurystyk. Są obecne specjalne mechanizmy pilnujące, że daną definicję metody przypiszemy do danego wywołania tylko raz (bo wywołania mogą być przetwarzane więcej niż raz). Następnie, jeśli w efekcie przetwarzania metod zostały dodane jakieś wierzchołki do kolejki, to wracamy do etapu przetwarzania wierzchołków. Jeżeli żadne nie zostały dodane, to przetwarzamy znowu wywołania metod, tym razem obsługując wywołanie nawet wtedy, jeśli któryś z argumentów nie jest zdefiniowany.

Algorytm 4: Pseudokod funkcji typującej pojedyńczy wierzchołek

```
1 function processNode (node):
2 nodeCounter[node]++
3 if nodeCounter[node] < 100 then
      currentType = types[node]
      types[node] = computeType(node, graph.incomingVertices(node))
5
      if currentType \neq types[node] then
6
7
          for targetNode \in graph.adjacentVertices(node) do
             nodesWorklist.push(targetNode)
 8
9
          end
      end
10
11 end
```

## 4.3. Heurystyki obsługi wywołań

Na początku sprawdzamy czy wywołanie nie pasuje do jednej z heurystyk opisanych poniżej (Alg. 5). W przeciwnym przypadku zakładamy że to jest zwykłe wywołanie, które w szczególe zostanie omówione w następnej sekcji.

Algorytm 5: Pseudokod funkcji przetwarzającej wywołanie metody

```
1 function processMessageSend (messageSend):
2 for possibleType \in types[messageSend.sendObj].possibleTypes do
      {f if}\ messageAlreadyHandledByType?(messageSend,\ possibleType)\ {f then}
          next
4
      end
5
      messageName = messageSend.name;
6
      if possibleType.is?(ClassType) and messageName = 'new' then
          handleConstructorSend(possibleType.name, messageSend);
      else if possibleType.is?(ProcType) and messageName = 'call' then
          handleProcCall(possibleType, messageSend);
10
      else if possible Type.is?(Class Type) then
11
          handleClassSend(possibleType.name, messageSend);
12
13
      else
          handleInstanceSend(possibleType.name, messageSend);
14
15
      markMessageSendAsHandled(messageSend, possibleType)
16
17 end
```

Po pierwsze, wywołanie może wyglądać jak wywołanie konstruktora, tj. jest wywoływana metoda new na typie reprezentującym klasę (Alg. 6). Ten przypadek jest prawie taki sam jak obsłużenie zwykłego wywołania metody z tą różnicą, że zamiast zwrócić wynik konstruktora, dodajemy do grafu specjalny wierzchołek rodzaju constructor i podajemy mu nazwę inicjalizowanej klasy jako parametr (Alg. 7). Dodajemy potem krawędź między tym wierzchołkiem, a wierzchołkiem wyniku metody. Obsługa tego specjalnego wierzchołka to pobranie parametru i zwrócenie

go jako GenericType (jeśli nazwa klasy jest klasą generyczną Array lub Hash) lub NominalType (Alg. 8). Dzięki temu, zwracamy (jako wynik wywołania konstruktora) typ instancji zamiast typu klasowego na którym konstruktor był wywołany, tj. jeżeli konstruktor był wywołany na wierzchołku typu ClassType(Foo) to zwracamy typ NominalType(Foo).

#### Algorytm 6: Pseudokod funkcji obsługującej wywołanie konstruktora

```
    1 function handleConstructorSend (className, messageSend):
    2 constructorMethod = database.findInstanceMethodFromClassName(className, 'initialize');
    3 if constructorMethod then
```

4 connectConstructorToCallResult(className, messageSend.resultNode);

- 5 else
   6 handleRegularMessageSend(constructorMethod, messageSend);
- 7 connectConstructorToCallResult(className, messageSend.resultNode);
- 8 end

# **Algorytm 7:** Pseudokod funkcji dołączającej specjalny wierzchołek konstruktora

```
1 \underline{\text{function connectConstructorToCallResult}} (className, resultNode):
```

- 2 constructorNode = Node('constructor', name: className);
- 3 graph.addEdge(constructorNode, resultNode);
- 4 nodesWorklist.push(constructorNode);

#### Algorytm 8: Fragment funkcji typującej obsługującej konstruktor

Drugim przypadkiem jest kiedy obiekt na którym wywołujemy metodę jest typu ProcType, a nazwa metody to call. Oznacza to wywołanie funkcji anonimowej. W ProcType trzymamy identyfikator funkcji anonimowej, wystarczy go więc tylko pobrać i wyciągnąć z bazy definicję funkcji (Alg. 9). Reszta procedury jest taka jak w przypadku zwykłego wywołania metody.

Trzeci przypadek to metoda klasowa (Alg. 10). Uznajemy wywołanie za wywołanie metody klasowej, jeśli obiekt na którym wywołujemy metodę jest pewnego typu klasowego, tj. ClassType. W tym przypadku jedyną różnicą od zwykłego wywołania jest zapytanie do bazy danych, które szuka metod zdefiniowanych na eigenclass, a nie w definicji klasy.

**Algorytm 9:** Pseudokod funkcji obsługującej wywołanie funkcji anonimowej

- 1 <u>function handleProcCall</u> (lambdaType, messageSend):
- 2 foundLambda = database.getLambda(lambdaType.lambdaId);
- 3 connectActualArgsToFormalArgs(messageSend.args, foundLambda.args);
- 4 graph.addEdge(foundLambda.resultNode, messageSend.resultNode);
- 5 nodesWorklist.push(messageSend.resultNode);

# **Algorytm 10:** Pseudokod funkcji obsługującej wywołanie metody klasowej

- 1 <u>function handleClassSend</u> (className, messageSend):
- з if foundMethod then
- 4 handleRegularMessageSend(foundMethod, messageSend);
- connectMethodResultToResultNode(foundMethod.nodes, messageSend.resultNode);
- 6 end

Tak jak zostało wspomniane wyżej, jeżeli żaden z tych przypadków nie zachodzi, uznajemy wywołanie za klasyczne wywołanie metody na instancji pewnego obiektu (Alg. 11). Szukamy w takim wypadku metody o odpowiadającej do wywołania nazwie, która została zdefiniowana w klasie obiektu na którym metoda jest wywoływana.

# Algorytm 11: Pseudokod funkcji obsługującej wywołanie metody instancji

- 1 function handleInstanceSend (className, messageSend):
- з if foundMethod then
- 4 handleRegularMessageSend(foundMethod, messageSend);
- connectMethodResultToResultNode(foundMethod.nodes, messageSend.resultNode);
- 6 end

# 4.4. Obsługa wywołania

Po powyższych heurystykach możemy założyć, że mamy już znalezioną definicję metody, do której chcemy podłączyć wywołanie. Definicja, niezależnie od tego czy była to klasyczna definicja metody czy definicja funkcji anonimowej, ma obowiązkowo kilka właściwości: drzewo argumentów formalnych, wierzchołek wyniku

definicji, listę użyć bezargumentowego super, listę użyć słowa kluczowego yield (tj. wywołań bloków) oraz być może wierzchołek wywoływacza (wierzchołek wywoływacza jest specjalnym mechanizmem, opisanym dokładniej w sekcji poświęconej wywołaniom polimorficznym).

Najpierw następuje dodanie krawędzi między wierzchołkiem obiektu, na którym jest wywoływana metoda, oraz specjalnego wierzchołka rodzaju caller dla tej definicji metody, o ile on istnieje.

**Algorytm 12:** Pseudokod funkcji obsługującej łączenie wierzchołków metody z wierzchołkami wywołania

```
1 function handleRegularMessageSend (foundMethod, messageSend):
 2 nodes = foundMethod.nodes;
 з if nodes.caller then
      graph.addEdge(messageSend.sendObj, nodes.caller);
      nodesWorklist.push(nodes.caller);
 6 end
 7 connectActualArgsToFormalArgs(messageSend.args, foundMethod.args);
 s for zsuperCall \in nodes.zsupers do
      superMethod = database.findSuperMethod(foundMethod.id);
      if not superMethod then next;
10
      connectActualArgsToFormalArgs(messageSend.args, superMethod.args);
11
      if zsuperCall.block then
12
          connectYieldsToBlock(superMethod.nodes.yields, zsuperCall.block);
13
      end
14
      connectYieldsToBlock(superMethod.nodes.yields, messageSend.block);
15
      connectMethodResultToResultNode(superMethod, zsuperCall.resultNode);
17 end
18 connectYieldsToBlock(foundMethod.nodes.yields, messageSend.block);
```

Najważniejsza część to wspomniane już połączenie wierzchołków argumentów wywołania z wierzchołkami argumentów formalnych, oraz wierzchołka wyniku metody z wierzchołkiem wyniku wywołania. Są dwa powody, które utrudniają zrobienie poprawnego dopasowania argumentów wywołania i argumentów formalnych.

Pierwszym jest tzw. splat argument. Zarówno w argumentach wywołania (Rys. 4.1) jak i argumentach formalnych (Rys. 4.2), możemy użyć składni splat, która w przypadku argumentów wywołania spłaszcza przekazaną listę jako listę argumentów, a w przypadku argumentów formalnych buduje tablicę z przekazanych argumentów. Jest to mechanizm znany z wielu języków pozwalający na definiowanie i wywoływanie funkcji o zmiennej liczbie argumentów.

Drugi to named arguments czyli argumenty, które w wywołaniu muszą być przekazane razem z nazwą argumentu formalnego, ale dzięki temu mogą być przekazane w dowolnej kolejności. Niestety, jest to tylko pewna sztuczka głównie po stronie parsera. Mechanizm named arguments w Ruby polega na tym, że jeżeli ostatni przekazywany argument jest słownikiem, to jest traktowany jako słownik zawierający

```
WYWOŁANIE

obj.foo(*some_list)
obj.foo(y, *some_list)

DEFINICJA

def foo(a,b=5)
```

Rysunek 4.1: Trudność w dopasowaniu argumentów gdy splat argument użyty w argumentach wywołania. some\_list jest listą argumentów o nieznanej długości.

Rysunek 4.2: Trudność w dopasowaniu argumentów gdy splat argument użyty w argumentach formalnych. some\_list jest listą argumentów o dowolnej długości.

przekazywane named arguments. Z tego powodu, przekazywane argumenty wcale nie muszą być przekazywane explicit, ale mogą być przekazane np. przez zwykłą zmienną, która jest słownikiem (Rys. 4.3). Dlatego też aby poprawnie dopasować przekazane named arguments do tych w definicji wywołania, musielibyśmy śledzić dokładne mapowanie typów w każdym słowniku.

Rysunek 4.3: Trudność w dopasowaniu argumentów gdy *named arguments* pobrane z nieznanego słownika.

Trzecim etapem jest połączenie przekazanych argumentów do metody z klasy nadrzędnej oraz wyników tej metody z wszystkimi wywołaniami bezargumentowego super.

Kolejnym krokiem jest obsługa bloku (Alg. 13). Blok mamy przypisany do wywołania, z reguły w postaci albo w postaci wierzchołka z identyfikatorem funkcji anonimowej (tj. przekazany blok był znany już przy budowaniu grafu), albo wierzchołka grafu, który został otypowany na ProcType i zawiera w sobie identyfikator funkcji anonimowej. Następuje więc przejście po wszystkich użyciach słowa kluczowego yield w tej metodzie i połączeniu przekazanych do yield argumentów z argumentami formalnymi znalezionej funkcji anonimowej oraz wierzchołka wyniku funkcji anonimowej z wierzchołkiem wyniky yield. Jest to procedura identyczna do opisanego wyżej łączenia argumentów wywołania z argumentami formalnymi.

Na końcu, następuje połączenie wierzchołka wyniku metody oraz wierzchołka

Algorytm 13: Pseudokod obsługi bloku podczas wywołania

wyniku wywołania.

## 4.5. Wywołania funkcji polimorficznych

Jak już zostało wspomniane, definicja metody w Bazie ma w sobie kilka wierzchołków, które są istotne z punktu widzenia analizy, takie jak wierzchołek wyniku metody, wierzchołki argumentów i inne związane z blokami i wywołaniami bezargumentowego super. Te wierzchołki mogą zostać przechowywane na dwa sposoby. Pierwszy z nich to po prostu dokładnie te wierzchołki, które są obecne w grafie. Drugi sposób to przechowywanie szkicu podgrafu (tj. wierzchołki i krawędzie, które nie należą do grafu – są tylko wzorem), z którego przy okazji przetwarzania każdego wywołania są tworzone świeże wierzchołki.

Świeże wierzchołki dla każdego wywołania oznaczają też, że możemy skorzystać z typu wyrażenia na którym metoda została wywołana. Dlatego też, jeżeli obsługujemy wywołanie metody której definicja korzysta z podgrafu, łączymy wierzchołek wyrażenia na którym została wywołana metoda z wierzchołkiem rodzaju caller. Dzięki temu możemy bez problemu zbudować podgrafy działające poprawnie dla takich metod polimorficznych jak map z Array lub po prostu funkcje, które zwracają obiekt na którym zostały wywołane (nie było to możliwe bez podgrafu), takie jak np. freeze.

# 4.6. Inne wierzchołki specjalne

Podejście z podgrafami pozwala też na obsługę niektórych metod w specjalny sposób, bez dużej ingerencji w funkcję typującą. Przykładem takiej metody jest metoda class, którą możemy wywołać na dowolnym obiekcie, a która zwraca klasę tego obiektu. Dzięki podgrafowi, definicja takiej metody to tylko dwie krawędzie, widoczne na rysunku. Specjalny wierzchołek extract\_class na podstawie typu wierzchołka z krawędzi wejściowej zwraca odpowiedni typ, który zwróciłaby metoda

class. Na przykład, jeżeli typ wejściowy to NominalType(Foo), to typem wyjściowym będzie ClassType(Foo).

### 4.7. Pozostałe wierzchołki

Pozostałe wierzchołki są obsługiwane w bardzo prosty sposób. Część z nich zwraca ustalony typ, np. typ NominalType('String') dla wierzchołka rodzaju str. Inne, robią prostą operację na jednym z wejściowych typów, jak opakowanie wejściowych typów w typ generyczny tablicy. Pozostałe, po prostu biorą wszystkie wejściowe wierzchołki i tworzą zbiorczy typ UnionType z typów wierzchołków wejściowych.

# Rozdział 5.

# Podsumowanie

Głównym celem niniejszej pracy było podjęcie próby zaimplementowania wtyczki wspomagającej pracę programisty Ruby. Opracowany projekt spełnia ten cel przez dostarczenie funkcjonalności skoku do definicji i autouzupełniania, a autor tej pracy korzysta z tego projektu w codziennej pracy.

Pomimo dynamicznej natury języka Ruby udało się stworzyć narzędzie, które z zadowalającym efektem potrafi wywnioskować przybliżony typ wyrażeń, korzystając z grafu przepływu danych i heurystyk. Posiadanie tej informacji pozwoliłoby również zaimplementować szereg innych dodatkowych funkcjonalności obecnych w komercyjnych rozwiązaniach.

Największą wadą obecnego projektu jest konieczność uruchomienia od nowa funkcji typującej w przypadku zmiany kodu źródłowego. Ponieważ w praktyce programista spędza znacznie więcej czasu czytając kod, niż go pisząc, nie jest to wada czyniąca wtyczkę bezwartościową, ale utrudnia ona implementowanie niektórych funkcjonalności. Jednocześnie stworzenie takiego inkrementalnego algorytmu typującego byłoby zdecydowanie najciekawszym kierunkiem rozwoju tego projektu.

Drugą wadą projektu jest efektywność – cały projekt, jako projekt badawczy, został napisany w Ruby, czyli języku o wysokiej ekspresji, ale jednak języku interpretowanym i ze słabym wsparciem wielowątkowości. Oznaczało to, że przy bardzo dużych projektach indeksowanie potrafiło zająć kilkanaście minut. Projekt jest głównie ograniczony przez CPU, więc przepisanie go do dowolnego języka kompilowanego powinno dać znaczny skok wydajności.

Przez to, że projekt opiera się na heurystykach, jest wiele możliwości jego rozwoju, które pozwalałyby jeszcze dokładniej określać typ wyrażeń. Ponadto, sam system typów mógłby zostać rozbudowany, na przykład wprowadzając specjalne typy listy i tupli, zależnie od rodzaju inicjalizacji tablicy, podobnie jak to robi RDL [7]. Jeszcze innym, bardziej inżynieryjnym kierunkiem byłaby integracja z niektórymi dotychczasowymi narzędziami popularnymi w społeczności języka Ruby, takimi jak system dokumentacji YARD [12]. Integracja z systemami dokumentacji (które

często posiadają jakiś język opisu typów) pozwoliłoby również na szczątkową implementację silnego typowania, informującą programistę kiedy wywołanie funkcji jest używane z argumentami niepoprawnego typu.

# Bibliografia

- [1] Atom. URL: https://atom.io (term. wiz. 01. 10. 2018).
- [2] CTags project. URL: http://ctags.sourceforge.net (term. wiz. 01. 10. 2018).
- [3] Greg DeFouw, David Grove i Craig Chambers. "Fast Interprocedural Class Analysis". W: (1997).
- [4] GNU/Emacs. URL: https://www.gnu.org/software/emacs/ (term. wiz. 01.10.2018).
- [5] Język programowania Ruby. URL: https://www.ruby-lang.org/pl/ (term. wiz. 01.10.2018).
- [6] Language Server Protocol. URL: https://microsoft.github.io/language-server-protocol/ (term. wiz. 01.10.2018).
- [7] RDL Types, type checking, and contracts for Ruby. URL: https://github.com/plum-umd/rdl (term. wiz. 01.10.2018).
- [8] Robe. URL: https://github.com/dgutov/robe (term. wiz. 01. 10. 2018).
- [9] RubyMine: Ruby on Rails IDE by JetBrains. URL: https://www.jetbrains.com/ruby/ (term. wiz. 01.10.2018).
- [10] Solargraph. URL: https://github.com/castwide/solargraph (term. wiz. 01.10.2018).
- [11] Vim the ubiquitous text editor. URL: https://www.vim.org (term. wiz. 01.10.2018).
- [12] Yay! A Ruby Documentation Tool. URL: https://yardoc.org (term. wiz. 01.10.2018).